МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ им. Н.Э. Баумана

Факультет «Информатика и системы управления» Кафедра «Системы обработки информации и управления»

ОТЧЕТ

Лабораторная работа № 3 по дисциплине «Разработка нейросетевых систем»

Тема: «Обработка признаков, часть 2»

Москва – 2024

ИСПОЛНИТЕЛЬ: группа ИУ5-24М	<u>Кравцов А.Н</u>
	подпись
	"26" апреля 2024 г.
ПРЕПОДАВАТЕЛЬ:	<u>Гапанюк Ю.Е.</u> ФИО подпись
	""2024 г.

Задание

1. Выбрать один или несколько наборов данных (датасетов) для решения

следующих задач. Каждая задача может быть решена на отдельном

датасете, или несколько задач могут быть решены на одном датасете.

Просьба не использовать датасет, на котором данная задача решалась в лекции.

2. Для выбранного датасета (датасетов) на основе материалов лекций

решить следующие задачи: і. масштабирование признаков (не менее чем тремя способами); іі. обработку выбросов для числовых признаков (по одному способу

для удаления выбросов и для замены выбросов); ііі. обработку по крайней мере одного нестандартного признака

(который не является числовым или категориальным); iv. отбор признаков:

- ♣ один метод из группы методов фильтрации (filter methods);
- ♣ один метод из группы методов обертывания (wrapper methods);
- один метод из группы методов вложений (embedded methods).

```
Загрузка датасета
   data = pd.read_csv("winequalityN.csv")
       type fixed acidity volatile acidity citric acid residual sugar chlorides free sulfur dioxide total sulfur dioxide density pH sulphates alcohol quality
                                    0.36
                                                         0.045
                                                                        45.0
                                                                                        170.0 1.00100 3.00 0.45
   0 white
                                                                                           132.0 0.99400 3.30
                                       0.40
                                                                                           186.0 0.99560 3.19
   3 white
                                                                                                              0.40
                                                                                 44.0 0.99490 3.45 0.58 10.5
 6494
                                                                                            42.0 0.99549 3.39
 6496
                                       0.47
                                                            0.067
                                                                            18.0
                                                                                                                0.66
```

```
Устранение пропусков в данных

hdata = hdata_loaded
    list(zip(hdata.columns, [i for i in hdata.dtypes]))


(('show_id', dtype('o')),
    ('type', dtype('o')),
    ('director', dtype('o')),
    ('cast', dtype('o')),
    ('cast', dtype('o')),
    ('release_year', dtype('o')),
    ('release_year', dtype('o')),
    ('duration', dtype('o')),
    ('listed_in', dtype('o')),
    ('description', dtype('o'))]


# cols with missing values
    hcols_with_na = [c for c in hdata.columns if hdata[c].isnull().sum() > 0]
    hcols_with_na

['director', 'cast', 'country', 'date_added', 'rating', 'duration']
```


```
hcols_with_na = [c for c in data.columns if data[c].isnull().sum() > 0]
    hcols_with_na
     [(c, data[c].isnull().sum()) for c in hcols_with_na]
 [('fixed acidity', 10),
  ('volatile acidity', 8),
  ('citric acid', 3),
  ('residual sugar', 2),
  ('chlorides', 2),
  ('pH', 9),
  ('sulphates', 4)]
     [(c, data[c].isnull().mean()) for c in hcols_with_na]
 [('fixed acidity', 0.0015391719255040787),
  ('volatile acidity', 0.001231337540403263),
  ('citric acid', 0.00046175157765122367),
  ('residual sugar', 0.00030783438510081576),
  ('chlorides', 0.00030783438510081576),
  ('pH', 0.0013852547329536709),
  ('sulphates', 0.0006156687702016315)]
 data = data.dropna(axis=0, how='any')
    type fixed acidity volatile acidity citric acid residual sugar chlorides free sulfur dioxide total sulfur dioxide density pH sulphates alcohol quality
                                                                                    170.0 1.00100 3.00
                                                                                     132.0 0.99400 3.30
                          0.280
                                    0.40
                                                      0.050
                                                                                                         0.44
                                                                                     186.0 0.99560 3.19
                                                                                     38.0 0.99651 3.42
6491
6494
                          0.645
                                                                                      44.0 0.99547 3.57
6495
                                                                                      42.0 0.99549 3.39
```


```
data.reset index(inplace=True)
    hcols with na
    data
        index type fixed acidity volatile acidity citric acid residual sugar chlorides free sulfur dioxide total sulfur dioxide density pH sulphates alcohol quality
                                                                                                                                         170.0 1.00100 3.00
                                                                                                                                         132.0 0.99400 3.30
                                                 0.300
                                                                                            0.049
                                                                                                                   14.0
                                                                                                                                                                        0.49
                                                                                                                                                                        0.44
                                                 0.230
                                                                                            0.058
                                                                                                                   470
                                                                                                                                         186.0 0.99560 3.19
                                                                                                                                                                        0.40
                                                                                                                                         186.0 0.99560 3.19
                                                                                            0.058
                                                                                                                                                                        0.40
6458
        6491
                                  6.8
                                                                                                                   28.0
                                                                                                                                          38.0 0.99651 3.42
6459
         6492
                                                 0.600
                                                                                            0.090
                                                                                                                    32.0
                                                                                                                                          44.0 0.99490 3.45
                                                                                                                                          40.0 0.99574 3.42
                                                                                            0.076
                                                                                                                   29.0
6460
         6494
         6495
                                                                                                                                          42.0 0.99549 3.39
6462 6496
                                                               0.47
                                                                                            0.067
6463 rows × 14 columns
Масштабирование признаков
    # Нужно ли масштабирование data.describe()
                             fixed
acidity
                                            volatile
acidity
                                                                        residual
sugar
                                                                                                     free sulfur
dioxide
                                                                                                                     total sulfur
dioxide
                index
                                                       citric acid
                                                                                     chlorides
                                                                                                                                       density
                                                                                                                                                         рΗ
                                                                                                                                                                sulphates
                                                                                                                                                                                  alcohol
                                                                                                                                                                                                quality
  count 6463.000000 6463.000000
                                                                                                   6463.000000
  mean 3255.125793
                                          0.339589
                                                        0.318758
                                                                                     0.056056
                                                                                                     30.516865
                                                                                                                     115.694492
                                                                                                                                                                                               5.818505
                                                                                                                                     0.994698
                                                                                                                                                                             10.492825
    std 1869.906597
                                          0.164639
                                                        0.145252
                                                                        4.756852
                                                                                     0.035076
                                                                                                     17.758815
                                                                                                                      56.526736
                                                                                                                                     0.003001
                                                                                                                                                    0.160650
                                                                                                                                                                  0.148913
                                                                                                                                                                                1.193128
                                                                                                                                                                                               0.873286
                                          0.080000
                                                                                                                                                                                               3.000000
   25% 1639.500000
                           6.400000
                                                                        1.800000
                                                                                     0.038000
                                                                                                     17.000000
                                                                                                                      77.000000
                                                                                                                                                                  0.430000
                                                                                                                                                                                9.500000
                                                                                                                                                                                               5.000000
   50% 3257.000000
                                                                                                     29.000000
                                                                                                                                                                  0.510000
                                                                                                                                                                                               6.000000
                           7.000000
                                          0.290000
                                                        0.310000
                                                                        3.000000
                                                                                     0.047000
                                                                                                                     118.000000
                                                                                                                                     0.994890
                                                                                                                                                    3.210000
                                                                                                                                                                               10.300000
    75% 4872.500000
                           7.700000
                                          0.400000
                                                        0.390000
                                                                        8.100000
                                                                                     0.065000
                                                                                                     41.000000
                                                                                                                     156.000000
                                                                                                                                     0.997000
                                                                                                                                                    3.320000
                                                                                                                                                                  0.600000
                                                                                                                                                                               11.300000
                                                                                                                                                                                               6.000000
                                          1.580000
                                                                                                                     440.000000
     # DataFrame не содержащий целевой при
X_ALL = data.drop('quality', axis=1)
     # на основе масштабированных данных
def arr_to_df(arr_scaled):
res = pd.DataFrame(arr_scaled, columns=X_ALL.columns)
          return res
                                                                                                                                                                                                 Python
     X_train, X_test, y_train, y_test = train_test_split(X_ALL, data['quality'], test_size=0.2, random_state=1)
     # Преобразуем массивы в DataFrame
X_train_df = arr_to_df(X_train)
X_test_df = arr_to_df(X_test)
                                                                                                                                                                                                 Pytho
 ((5170, 13), (1293, 13))
```




















```
hcols_with_na = [c for c in data2.columns if data2[c].isnull().sum() > 0]
  hcols_with_na
  [(c, data2[c].isnull().sum()) for c in hcols_with_na]
  [(c, data2[c].isnull().mean()) for c in hcols_with_na]
  data2 = data2.dropna(axis=0, how='any')
  data2
      index
             citric acid
                        residual sugar
                                      alcohol
                                               quality
                                           8.8
                  0.36
                  0.34
                  0.40
                                  6.9
                  0.32
                                  8.5
                                           9.9
                  0.32
                                  8.5
                                           9.9
                                                     6
6458
       6491
                  80.0
```

citric acid - original





residual sugar - original








```
# Тип вычисления верхней и нижней границы выбросов
    from enum import Enum
    class OutlierBoundaryType(Enum):
        SIGMA = 1
        QUANTILE = 2
        IRQ = 3
    def get_outlier_boundaries(df, col, outlier_boundary_type: OutlierBoundaryType):
        if outlier_boundary_type == OutlierBoundaryType.SIGMA:
             lower_boundary = df[col].mean() - (K1 * df[col].std())
             upper_boundary = df[col].mean() + (K1 * df[col].std())
        elif outlier_boundary_type == OutlierBoundaryType.QUANTILE:
             lower_boundary = df[col].quantile(0.05)
             upper_boundary = df[col].quantile(0.95)
        elif outlier_boundary_type == OutlierBoundaryType.IRQ:
             K2 = 1.5
             IQR = df[col].quantile(0.75) - df[col].quantile(0.25)
             lower_boundary = df[col].quantile(0.25) - (K2 * IQR)
             upper_boundary = df[col].quantile(0.75) + (K2 * IQR)
        else:
             raise NameError('Unknown Outlier Boundary Type')
        return lower_boundary, upper_boundary
for col in x_col_list:
    for obt in OutlierBoundaryType:
     # Удаление данных на ocnose флага
data_trimmed = data2.loc[<(outliers_temp), ]
title = 'None-{}, werop_{}') .format(col, obt, data_trimmed.shape[@])
diagnostic_plots(data_trimmed, col, title)
```


















```
Отбор признаков
Методы фильтрации (filter methods)
    selector_1211 = VarianceThreshold(threshold=0.15)
    selector_1211.fit(data)
    selector_1211.variances_
array([3.49600967e+06, 1.85727591e-01, 1.68431767e+00, 2.71018852e-02,
       2.10949595e-02, 2.26241369e+01, 1.23012312e-03, 3.15326731e+02,
       3.19477751e+03, 9.00726891e-06, 2.58043973e-02, 2.21717714e-02,
       1.42333473e+00, 7.62510717e-01])
    selector_1211.transform(data)
array([[0, 0, 7.0, ..., 170.0, 8.8, 6],
       [1, 0, 6.3, ..., 132.0, 9.5, 6],
       [2, 0, 8.1, ..., 97.0, 10.1, 6],
       [6494, 1, 6.3, ..., 40.0, 11.0, 6],
       [6495, 1, 5.9, ..., 44.0, 10.2, 5],
        [6496, 1, 6.0, ..., 42.0, 11.0, 6]], dtype=object)
```



```
Корреляций 0.8 и выше нет
```

```
make_corr_df(data, 0.5)
65]
                                                f2
                                                         corr
          total sulfur dioxide free sulfur dioxide 0.721476
          free sulfur dioxide total sulfur dioxide 0.721476
                     alcohol
                                          density 0.687432
      2
      3
                     density
                                          alcohol 0.687432
          total sulfur dioxide
                                            index 0.596102
      4
      5
                               total sulfur dioxide 0.596102
                       index
      6
                     density
                                    residual sugar 0.551494
      7
               residual sugar
                                          density 0.551494
     # Обнаружение групп коррелирующих признаков
     def corr_groups(cr):
         grouped_feature_list = []
         correlated_groups = []
         for feature in cr['f1'].unique():
             if feature not in grouped_feature_list:
                 # находим коррелирующие признаки
                correlated_block = cr[cr['f1'] == feature]
                 cur_dups = list(correlated_block['f2'].unique()) + [feature]
                grouped_feature_list = grouped_feature_list + cur_dups
                correlated_groups.append(cur_dups)
         return correlated_groups
     # Группы коррелирующих признаков
     corr_groups(make_corr_df(data, 0.5))
 [['free sulfur dioxide', 'index', 'total sulfur dioxide'],
  ['density', 'alcohol'],
  ['density', 'residual sugar']]
```

```
Методы обертывания (wrapper methods)
  from mlxtend.feature_selection import ExhaustiveFeatureSelector as EFS
  efs1 = EFS(knn,
min_features=2,
         max_features=4,
scoring='accuracy',
print_progress=True,
  print('Best accuracy score: %.2f' % efs1.best_score_)
print('Best subset (indices):', efs1.best_idx_)
print('Best subset (corresponding names):', efs1.best_feature_names_)
Методы вложений (embedded methods)
    e_lr1 = LogisticRegression(C=1000, solver='liblinear', penalty='l1', max_iter=500, random_state=1)
    e_lr1.fit(X_test, y_test)
    e_lr1.coef_
 array([[ 2.32506550e-03, -8.16523994e+00, -1.22362024e+00,
     # Все 12 признаков являются "хорошими"
     sel_e_lr1 = SelectFromModel(e_lr1)
     sel_e_lr1.fit(X_test, y_test)
     sel_e_lr1.get_support()
 array([ True, True, True, True, True, True, True, True, True,
           True, True, True, True])
     e_lr2 = LinearSVC(C=0.01, penalty="11", max_iter=2000, dual=False)
     e_lr2.fit(X_test, y_test)
     # Коэффициенты регрессии
     e_lr2.coef_
```

```
# Признаки 1,3,4,6,9,11 исключены
   sel_e_lr2 = SelectFromModel(e_lr2)
   sel_e_lr2.fit(X_test, y_test)
   sel_e_lr2.get_support()
array([ True, False, True, False, False, True, False, True, Tr
       False, True, False, True])
   # Используем L1-регуляризацию
   e_ls1 = Lasso(random_state=1)
   e_ls1.fit(X_test, y_test)
   # Коэффициенты регрессии
   list(zip(x_col_all, e_ls1.coef_))
[('type', -4.05281522319424e-05),
('fixed acidity', -0.0),
 ('volatile acidity', -0.0),
 ('citric acid', -0.0),
 ('residual sugar', 0.0),
('chlorides', 0.0),
('free sulfur dioxide', -0.0),
 ('total sulfur dioxide', 0.002751714205935953),
 ('density', -0.0017997923625971046),
 ('pH', -0.0),
 ('sulphates', -0.0),
 ('alcohol', 0.0),
('quality', 0.0)]
```

```
sel_e_ls1 = SelectFromModel(e_ls1)
      sel_e_ls1.fit(X_test, y_test)
      list(zip(x_col_all, sel_e_ls1.get_support()))
6]
   [('type', True),
   ('fixed acidity', False),
    ('volatile acidity', False),
   ('citric acid', False),
    ('residual sugar', False),
   ('chlorides', False),
    ('free sulfur dioxide', False),
   ('total sulfur dioxide', True),
   ('density', True),
   ('pH', False),
    ('sulphates', False),
   ('alcohol', False),
    ('quality', False)]
```